ASIGNATURA:
SEMINARIO DE TESIS III

Sesión 9:

Consolidación y control de calidad de los datos

Unidad III · Capítulo IV: Resultados · Semana 9 · Semestre 2026-II

MBA Jenny Reynoso Palpa

Ruta de la sesión

Seis bloques para pasar de dos bases «crudas» a una base consolidada, depurada, codificada y documentada

1. Presentación y ficha del sílabo — 20 min

Ubicación en el curso, perfil metodológico, insumos y producto esperado

2. Marco conceptual — 45 min

Base consolidada, codificación, diccionario, correspondencia, perdidos, atípicos, errores y trazabilidad

3. Protocolo en 7 pasos — 35 min

De inventariar y congelar el RAW hasta documentar y liberar la versión 1.0

4. Caso aplicado — 30 min

Municipalidad de Huánuco: 16 hallazgos sembrados y sus decisiones

5. Laboratorio y revisión cruzada — 80 min

Cuaderno Excel con bases RAW, conciliación, control de calidad y bitácora

6. Instrumentos y cierre — 15 min

Lista de cotejo, ficha de control de calidad, rúbrica, revisión del diccionario

Ficha del sílabo (1/2): contenidos de la semana 9

Unidad III · Capítulo IV: Resultados · Contenido temático: Consolidación y control de calidad de los datos

Contenido conceptual

- Base consolidada
- Codificación
- Diccionario de variables
- Correspondencia pretest–postest
- Valores perdidos
- Datos atípicos
- Errores y trazabilidad

Contenido procedimental

- Integra las bases de pretest y postest
- Verifica la correspondencia de participantes
- Codifica variables
- Identifica duplicados, datos faltantes y atípicos
- Aplica criterios de depuración
- Documenta las decisiones adoptadas

Ficha del sílabo (2/2): actitudes, metodología y evaluación

Contenido actitudinal

Precisión, confidencialidad, honestidad, transparencia, perseverancia y responsabilidad frente a la integridad de los datos.

Metodología

Laboratorio de datos; aprendizaje basado en evidencias; revisión cruzada; resolución de problemas y control de calidad.

Indicador de logro

Presenta una base consolidada, depurada, codificada y documentada, sin inconsistencias sustantivas y con decisiones justificadas.

Instrumentos de evaluación

- Lista de cotejo de base de datos
- Ficha de control de calidad
- Rúbrica de depuración
- Revisión del diccionario de variables

¿Dónde estamos? Mapa de las 16 semanas del curso

La semana 9 abre la Unidad III: es el puente entre la ejecución (TA1 y TA2) y el análisis estadístico (TA3)

Unidad I · Pretest e inicio de la solución	Unidad II · Implementación, monitoreo y postest	Unidad III · Capítulo IV: Resultados	Unidad IV · Discusión e informe final

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
			TA1			TA2	Parcial	HOY			TA3			TA4	Final

Viene de

- S3: base del pretest y diccionario v0
- S7: base del postest, mortalidad y acta de cierre

Hoy (S9)

- Integrar, conciliar, codificar
- Depurar y documentar
- Liberar la base v1.0

Alimenta a

- S10: resultados descriptivos
- S11: supuestos y prueba
- S12: contrastación y Cap. IV

Perfil metodológico que sostiene la sesión

Tipo: Aplicada

Resuelve un problema concreto con una solución tecnológica

Enfoque: Cuantitativo

Mide variables numéricas y contrasta hipótesis con estadística

Nivel: Aplicativo

Interviene sobre un proceso o sistema para mejorarlo

Diseño: preexperimental o cuasi

Medición antes (O_1) y después (O_2) de la intervención (X)

Notación del diseño

Preexperimental (un grupo): $G: \quad O_1 \quad X \quad O_2$

Cuasiexperimental (dos grupos):

$GE: \; O_1 \quad X \quad O_2 \qquad GC: \; O_3 \quad - \quad O_4$

O_1/O_3 = pretest · X = solución tecnológica · O_2/O_4 = postest

Implicancia para esta sesión

El mismo participante (o la misma unidad de observación) se mide dos veces. Las pruebas de la Sesión 11 trabajan con las diferencias $O_2 - O_1$; por eso la correspondencia pretest–postest por código es una condición de validez, no un detalle administrativo.

De dónde vienen los datos y hacia dónde van

Insumos (TA1 y TA2)

- Base del pretest (S3) y diccionario v0
- Base del postest con sufijo _POST (S7)
- Registro de participación final y mortalidad (S7)
- Actas de aplicación, registro de incidencias
- Instrumentos físicos foliados y logs del sistema
- Tabla código–identidad (custodiada aparte)

Sesión 9

- Integrar por clave
- Conciliar la correspondencia
- Codificar y derivar
- Depurar con criterios
- Documentar
- Liberar v1.0

Salidas

- S10: caracterización de la muestra y descriptivos pre–post
- S11: hipótesis estadísticas y verificación de supuestos
- S12: contrastación, tamaño del efecto y Capítulo IV
- Anexo 8: bases codificadas (pre, post y consolidada)
- Anexo 9: diccionario de variables

Indicador de logro y producto de la sesión

Presenta una base consolidada, depurada, codificada y documentada, sin inconsistencias sustantivas y con decisiones justificadas.

Base consolidada v1.0

41 casos × 57 variables en el caso; formato ancho, protegida y versionada

Diccionario de variables v1.0

Nombre, etiqueta, tipo, nivel, códigos, rango, unidad, fuente, momento, fórmula

Bitácora de depuración

Una fila por hallazgo: valor original, valor nuevo, criterio, evidencia, responsable

Ficha de control de calidad + lista de cotejo

Indicadores con metas y semáforo; 14 criterios verificables antes de liberar

Estos cuatro productos se adjuntan a la Tarea Académica 3 y se convierten en los Anexos 8 y 9 del informe final

¿Por qué controlar la calidad de los datos antes de analizar?

«Basura entra, basura sale»: ninguna prueba estadística corrige un dato mal registrado



Características de calidad del dato (ISO/IEC 25012)

- **Exactitud:** El valor representa correctamente el hecho medido (48,0 días verificado vs. 264 «horas»)
- **Completitud:** Todos los valores esperados están presentes; los perdidos se conocen y se explican
- **Consistencia:** Sin contradicciones entre variables, hojas o momentos (fecha fin ≥ fecha inicio)
- **Credibilidad:** El dato es rastreable a una fuente verificable (folio, acta, log)
- **Actualidad:** El dato corresponde a la ventana de medición definida en el protocolo

Base consolidada: una sola matriz ordenada

Definición: matriz única que integra el pretest y el postest de la misma unidad de análisis mediante una clave común (código del participante).

Principio de datos ordenados (Wickham, 2014): cada fila es una observación, cada columna una variable y cada celda un solo valor.

Formato ancho: pre y post lado a lado (_PRE / _POST). Es el que piden la prueba t apareada y Wilcoxon en SPSS o Jamovi.

Formato largo: una fila por medición con la variable MOMENTO (1 = pre, 2 = post). Útil para gráficos y modelos mixtos.

Regla práctica: se consolida en formato ancho y se deriva el largo cuando haga falta, nunca al revés.

Formato ancho (una fila por participante)

ID	TIEMPO_PRE	TIEMPO_POST	DIF_TIEMPO
GE-001	12,4	7,1	−5,3
GE-002	9,8	5,9	−3,9
GC-001	11,0	11,3	0,3

Formato largo (una fila por medición)

ID	MOMENTO	TIEMPO
GE-001	1	12,4
GE-001	2	7,1
GE-002	1	9,8
GE-002	2	5,9

Dos situaciones típicas en tesis de Ingeniería de Sistemas

Criterio	Sujetos apareados	Observaciones de proceso
Unidad de análisis	Persona (usuario, trabajador, estudiante) medida antes y después	Transacción, pedido, consulta o registro del sistema
Clave de correspondencia	Código único del participante (GE-001)	No hay pareja 1:1; se identifica con MOMENTO y N° de observación
Ejemplo de variable	Satisfacción (Likert), conocimiento, percepción de usabilidad	Tiempo de respuesta (ms), tasa de errores, throughput
Estructura de la base	Formato ancho: _PRE y _POST en la misma fila	Formato largo: 30 filas «pre» y 30 filas «post»
Análisis en la Sesión 11	t de Student apareada o Wilcoxon; comparación de DIF entre GE y GC	t para muestras independientes o U de Mann-Whitney
Correspondencia que se verifica	Que cada pretest tenga su postest del mismo sujeto	Que ambas ventanas midan el mismo proceso bajo las mismas condiciones

Muchos proyectos combinan ambas situaciones: una ficha de observación (proceso) y un cuestionario (sujetos). Cada una se consolida en su propia matriz.

Codificación (1): nombres y estructura de la base

Reglas de organización de datos en hojas de cálculo (Broman & Woo, 2018)

- Nombres de variables sin espacios, tildes ni símbolos; mayúsculas o snake_case; máximo 32 caracteres.
- Sufijos de momento (_PRE, _POST) y prefijos de dimensión (D1_, S01_) siempre iguales en ambas bases.
- Una sola tabla rectangular por hoja: sin celdas combinadas, subtotales, notas al pie ni filas vacías.
- El color y el formato no son datos: lo que se quiera registrar va en una columna.
- Una cosa por celda: el valor sin unidad ni comentario (la unidad vive en el diccionario).
- Fechas en formato ISO (AAAA-MM-DD) y decimales con punto; ningún «≈», «?» o «N/A» dentro de celdas numéricas.

Evitar	Usar
Tiempo de respuesta (seg.)	TIEMPO_RESP
satisfacción pre	SAT_TOTAL_PRE
Ítem 4 (invertido)	S04_PRE
Grupo: experimental	GRUPO = 1
Sí / No	1 / 0
25/08/26	2026-08-25
8,5 seg	8.5
Celda en rojo = revisar	FLAG_REVISAR = 1

Codificación (2): niveles, categorías, inversos y perdidos

Nivel de medición	Ejemplo en el caso	Cómo se codifica	Qué análisis admite
Nominal	SEXO, GRUPO, CARGO	Números con etiqueta: 1 = Masculino; 2 = Femenino	Frecuencias, χ^2, McNemar
Ordinal	NIVEL_SAT (bajo/medio/alto); ítems Likert	Enteros ordenados: 1 < 2 < 3 (… 1–5)	Mediana, Wilcoxon, Mann-Whitney
Intervalo	SAT_TOTAL (suma de 15 ítems)	Puntaje numérico derivado	Media, DE, t apareada (si hay normalidad)
Razón	TIEMPO (días), CUMPLE (%)	Valor exacto con unidad en el diccionario	Todo lo anterior; razones y porcentajes

Ítems inversos

Se recodifican ANTES de sumar: valor nuevo = (máximo + mínimo) − valor registrado. En Likert 1–5: 6 − x. Se declara en el diccionario y se conserva el valor original en la copia de trabajo.

Códigos de valor perdido

Celda vacía en Excel; 999 (o −1) declarado como perdido en SPSS. Nunca 0, nunca un texto («NA», «?»), porque entran en promedios y sumas sin avisar.

Puntajes derivados, diferencias y baremos

Dimensión: promedio (o suma) de sus ítems ya recodificados; perdida si falta algún ítem no imputado.

Total: suma de los 15 ítems (rango teórico 15–75); nunca se calcula con celdas vacías.

Nivel (baremo): puntos de corte justificados en el Capítulo III; en el caso, tercios del rango teórico.

Diferencia: DIF = POST − PRE por participante; es el insumo de la prueba apareada (S11) y del tamaño del efecto (S12).

Trampa de Excel: PROMEDIO y SUMA ignoran las celdas vacías y devuelven un valor «normal»; use CONTAR para exigir el número completo de ítems.

Fórmulas de la base consolidada

S04_PRE (inverso)

```
=SI(x="";"";6−x)
```

D1_PRE

```
=SI(CONTAR(S01:S05)<5;"";
    PROMEDIO(S01:S05))
```

SAT_TOTAL_PRE

```
=SI(CONTAR(S01:S15)<15;"";
    SUMA(S01:S15))
```

NIVEL_SAT_PRE

```
=SI(T<=35;1;SI(T<=55;2;3))
```

DIF_TIEMPO

```
=SI(O(PRE="";POST="");"";POST−PRE)
```

Diccionario de variables (codebook)

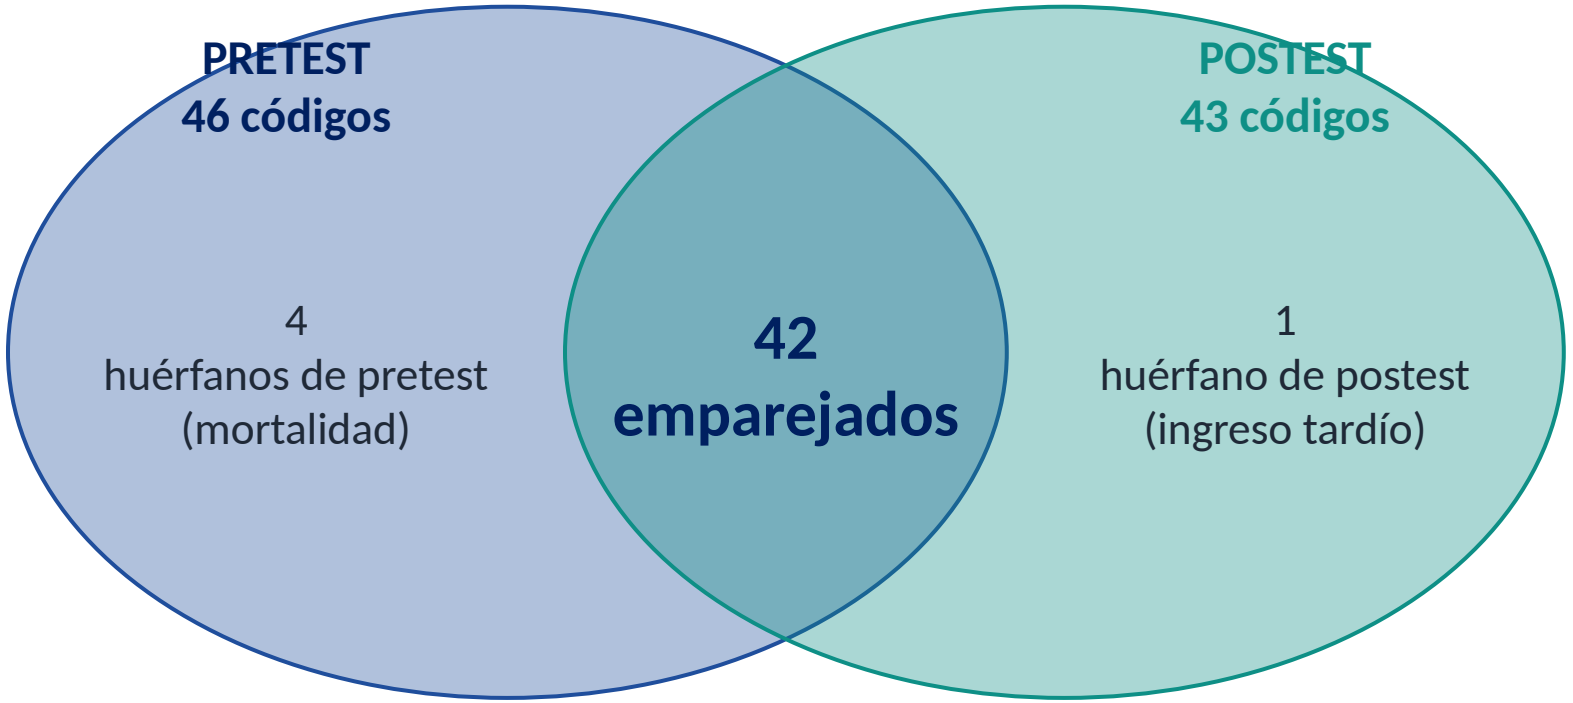
12 campos: nombre, etiqueta, tipo, nivel, códigos, rango, unidad, instrumento/ítem, momento, derivación, código de perdido y versión

Variable	Etiqueta	Tipo / nivel	Códigos / rango	Fuente · momento	Derivación
GRUPO	Grupo de estudio	Entero / nominal	1 = GE; 2 = GC	Protocolo · ambos	—
TIEMPO_PRE	Tiempo promedio de atención (pretest)	Numérico / razón	0,5–60 días	Ficha documental, ítem 1 · pretest	Σ días ÷ n exp.
S04_PRE	Ítem 4 de satisfacción [inverso]	Entero / ordinal	1–5	Cuestionario, ítem 4 (D1) · pretest	6 − valor
SAT_TOTAL_POST	Satisfacción total (postest)	Entero / intervalo	15–75 puntos	Derivada · postest	Suma de 15 ítems
NIVEL_SAT_POST	Nivel de satisfacción (postest)	Entero / ordinal	1 Bajo (15–35) · 2 Medio (36–55) · 3 Alto (56–75)	Derivada · postest	Tercios del rango
FLAG_IMP	Indicador de imputación	Entero / nominal	0 = no; 1 = sí	Depuración	—

Diccionario completo (57 variables) en la hoja 7_Diccionario del cuaderno; se adjunta como Anexo 9.

Correspondencia pretest–postest: emparejar por clave única

Sin correspondencia verificada no hay prueba apareada válida: cada O_1 debe unirse con el O_2 del mismo participante



42 emparejados − 1 retiro de consentimiento = 41 casos analizados (GE 21, GC 20)

Duplicados

Mismo código dos veces: exactos o con valores distintos

Claves inconsistentes

«ge-012», «GC-17», «GE 012»: no cruzan con GE-012 / GC-017

Retiro de consentimiento

Se excluye y se registra

La tabla de conciliación: cada código tiene una explicación

Indicador	GE	GC	Total	Fuente de verificación
Códigos en el pretest	24	22	46	Base del pretest (TA1)
Registros en el postest (RAW)	22	22	44	Base del postest (TA2)
Duplicados eliminados	0	1	1	COUNTIF(ID) > 1
Códigos únicos en el postest	22	21	43	Tras normalizar «ge-012» y «GC-17»
Emparejados (pre ∩ post)	22	20	42	Combinación por clave
Huérfanos de pretest (sin postest)	2	2	4	Registro de mortalidad (S7)
Huérfanos de postest (sin pretest)	0	1	1	Ingreso tardío: excluido
Retiro de consentimiento	1	0	1	Registro ético: excluido
Casos analizados (completos apareados)	21	20	41	Base consolidada v1.0

Regla: huérfanos + duplicados + retiros = 0 sin explicación. El n final (41) es el que se reporta en el apartado 4.1 del Capítulo IV.

Valores perdidos (1): tipos y mecanismos

Perdido de ítem (item nonresponse)

El participante respondió el instrumento, pero dejó una celda en blanco (p. ej., S13_PRE). Se trata dentro de la escala.

Perdido de unidad (unit nonresponse)

Falta todo el postest del participante: es mortalidad experimental. Se trata en la conciliación, no imputando.

MCAR · Completamente al azar

La ausencia no depende de nada: el aplicador olvidó escanear un folio. Casos completos sin sesgo.

MAR · Al azar condicional

Depende de otras variables observadas: los auxiliares omiten más el ítem 13. Se puede modelar o imputar.

MNAR · No al azar

Depende del valor perdido: quien está insatisfecho no responde satisfacción. Sesgo que debe declararse como limitación.

Clasificación de Rubin (1976); tratamiento en Little y Rubin (2019) y Enders (2022). En tesis de pregrado basta describir el mecanismo plausible y justificar el tratamiento.

Valores perdidos (2): cuantificar y decidir con umbrales

- Calcule la tasa de perdidos por variable, por caso y global (celdas vacías ÷ celdas esperadas).
- Revise el patrón: ¿se concentran en un ítem, en un grupo, en un aplicador o en un día?
- Intente recuperar antes de aceptar: folio físico, log del sistema, acta o registro documental.
- Decida con un umbral declarado y la misma regla para todos los casos (nunca caso por caso según convenga).
- Reporte en el Capítulo IV el n válido de cada prueba y en el Capítulo V la limitación si la tasa fue alta.

Umbrales de referencia para la tasa de perdidos

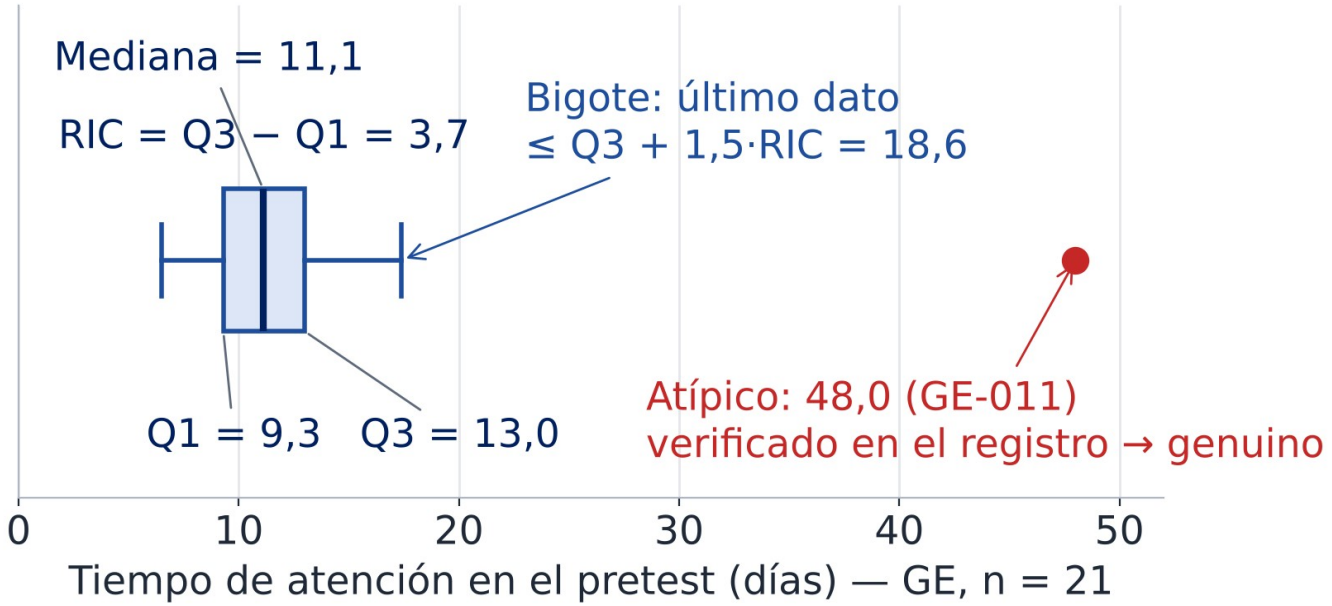
< 5 %	Análisis de casos completos: sesgo despreciable
5 – 20 %	Describir el mecanismo; imputación simple justificada en escalas
20 – 40 %	Limitación seria: imputación múltiple o excluir la variable
> 40 %	Solo exploratorio: no contrastar hipótesis con esa variable

Umbrales de referencia: Schafer (1999), Bennett (2001), Jakobsen et al. (2017).

Valores perdidos (3): criterios de decisión del curso



Datos atípicos (1): detectarlos con reglas explícitas



Regla de Tukey (1977): atípico si $x < Q1 - 1{,}5 \cdot RIC$ o $x > Q3 + 1{,}5 \cdot RIC$; extremo con $3 \cdot RIC$.

Puntaje z: $|z| > 3$; poco fiable con $n < 30$ porque el propio atípico infla la DE.

MAD (Leys et al., 2013): desviación absoluta mediana con umbral 2,5–3; robusta para muestras pequeñas.

Siempre por grupo y por momento: GE y GC tienen distribuciones distintas; el pretest y el postest también.

Causa del atípico	Ejemplo del caso	Acción
Error de registro o unidad	264 «horas» en una columna de días	Corregir con la fuente
Error de digitación	Edad = 7	Corregir con la ficha
Valor genuino extremo	48,0 días: expediente complejo	Conservar y analizar sensibilidad

Datos atípicos (2): decidir sin manipular el resultado

Atípico detectado → **Verificar en la fuente primaria** → **Decidir con un criterio declarado**

Error demostrable	Corregir con el valor de la fuente; registrar original y nuevo
Imposible de verificar	Marcar como perdido (no como 0 ni como la media)
Valor genuino	Conservar; reportar análisis de sensibilidad con y sin el caso
Muchos genuinos (> 5 %)	Winsorizar o transformar solo con justificación teórica; preferir pruebas no paramétricas

En diseños apareados, revise también los atípicos de la diferencia POST − PRE: son los que entran a la prueba t apareada y a Wilcoxon.



Prohibido: eliminar casos «incómodos» para mejorar el p-valor (p-hacking). Es falta de integridad académica (Aguinis et al., 2013).

Tipología de errores en bases de tesis y cómo detectarlos

Tipo de error	Ejemplo	Cómo se detecta
Transcripción / digitación	45 → 54; edad 7 en lugar de 37	Rango válido, doble digitación, verificación contra folio
Rango	Likert = 6; porcentaje = 105	CONTAR.SI fuera de rango; validación de datos
Formato	«8,5» como texto; fecha 16-10-26	ESNUMERO, ESFECHA; formato condicional
Unidad	264 horas en una columna de días	Diagrama de caja; máximo vs. rango esperado
Consistencia lógica	Experiencia 25 años con 23 de edad; postest antes del pretest	Reglas cruzadas entre columnas
Duplicidad	GC-005 dos veces; GE-003 con dos valores	CONTAR.SI(ID) > 1; comparación fila a fila
Codificación	CARGO como texto («Tecnico », «TÉCNICO»); inversos sin recodificar	Frecuencias por categoría; suma de ítems
Estructura	Celdas combinadas, dos valores en una celda, hojas distintas por grupo	Inspección de la matriz; importar a SPSS/R

Reglas de validación: duras, blandas y su implementación

Reglas duras (imposibles): corregir o perder

Likert fuera de 1–5; porcentaje > 100; tiempo ≤ 0; fecha de postest fuera de la ventana; código fuera del patrón.

Reglas blandas (improbables): verificar

Experiencia > edad − 18; atípicos de Tukey; cambio de 40 puntos en satisfacción; 0 errores en 30 transacciones.

Excel / Calc

=CONTAR.SI(A:A;A2)>1 → duplicados

=CONTAR.SI(F:F;">5") → fuera de rango

=ESNUMERO(H2) → texto en numéricos

Datos → Validación de datos (listas y rangos)

Formato condicional sobre reglas

SPSS / Jamovi

Frecuencias de todas las variables

Explorar → diagrama de caja y extremos

Identificar casos duplicados (Datos)

Definir valores perdidos (Vista de variables)

Validación de datos (módulo)

Python / R

```
df.duplicated('ID').sum()
df.isna().mean()
pd.merge(pre, post,
on='ID',
   how='outer')
dplyr::full_join(pre,
post,
   by='ID')
```

Doble digitación y revisión cruzada: controlar al que controla

Doble digitación

- Otra persona re-digita el 100 % (n pequeño) o el 10–20 % de los folios.
- Se compara celda a celda (=A2<>B2) y cada discrepancia se resuelve con el folio.
- Discrepancia aceptable: < 1 % de celdas (Barchard y Pace, 2011; Paulsen et al., 2012).

Revisión cruzada entre pares (hoy)

- Cada equipo revisa la base de otro con la lista de cotejo de 14 criterios.
- El revisor no corrige: registra observaciones; el autor decide y documenta.
- La ficha de control de calidad firmada por ambos acompaña la entrega.

1. Intercambiar bases y bitácoras
2. Aplicar la lista de cotejo
3. Recalcular 3 indicadores al azar
4. Devolver observaciones escritas
5. Autor corrige y documenta
6. Ambos firman la ficha

Trazabilidad (1): la cadena de custodia del dato

Toda cifra del Capítulo IV debe poder rastrearse hacia atrás hasta un folio, un código, una fecha y un acta



Instrumento foliado	Código	Captura	RAW congelado	Copia de trabajo	Consolidada v1.0	Capítulo IV
folio N° 015	GE-015	digitación / exportación	solo lectura + hash	correcciones con bitácora	bloqueada y versionada	tablas y figuras

El RAW nunca se edita

La base «tal como se recibió» se guarda en una carpeta de solo lectura con fecha y hash (p. ej., SHA-256). Si algo sale mal, siempre se puede volver al origen.

La v1.0 se congela antes de analizar

Una vez liberada, no se cambia una celda sin crear la versión 1.1 y registrar el motivo. Así el Capítulo IV y los anexos siempre coinciden.

Trazabilidad (2): versionado y bitácora de depuración

Nombres con versión y fecha

- BD_PRETEST_RAW_2026-08-31.xlsx
- BD_POSTEST_RAW_2026-10-19.xlsx
- BD_CONSOLIDADA_v1.0_2026-10-24.xlsx
- Nunca «final», «final2», «ahora sí final»

Principio

«Lo que no está en la bitácora no existió». La bitácora es la evidencia de honestidad y transparencia: permite que el asesor o el jurado reconstruyan cada cambio (Peng, 2011).

Campos de la bitácora de depuración

Campo	Contenido
N° y fecha	Correlativo y día de la decisión
Archivo / hoja	Dónde se detectó (p. ej., 2_POST_RAW)
Código y variable	GC-016 · TIEMPO_POST
Valor original → nuevo	264 → 11.0
Tipo de hallazgo	Atípico por error de unidad
Criterio aplicado	Regla de la Sesión 9 que justifica la decisión
Evidencia	Ficha, folio, log, acta o registro consultado
Responsable y revisor	Tesista y par que verificó

Integridad y confidencialidad de los datos

Seudonimización

La base de análisis solo lleva códigos; la tabla código–identidad se guarda aparte, cifrada y bajo custodia del tesista.

Marco legal y ético

Ley N.° 29733 de Protección de Datos Personales y su reglamento; Código de Ética en Investigación de la UDH; consentimiento informado.

Acceso mínimo

Solo tesista y asesor acceden a la base; ningún envío por mensajería o correo sin cifrado ni contraseña.

Respaldo 3-2-1

Tres copias, en dos medios distintos, una fuera del equipo (nube institucional); respaldo antes y después de cada versión.

Integridad verificable

Hash de cada versión liberada; hoja protegida; cambios solo por nueva versión documentada.

Retiro de consentimiento

Si un participante se retira, sus datos salen del análisis y el hecho se registra; no se reemplaza ni se imputa.

Protocolo de consolidación y control de calidad en 7 pasos

Los pasos siguen los verbos del contenido procedimental del sílabo: integrar, verificar, codificar, identificar, aplicar y documentar



Duración de referencia (dos instrumentos, dos grupos): 6 a 10 horas de trabajo del tesista, más la revisión cruzada.

Paso 1: inventariar las fuentes y congelar el RAW

1

Paso 1 de 7 · Inventariar y congelar el RAW

Inventario de insumos (antes de empezar)

- Base del pretest: n, columnas, fecha de cierre, versión
- Base del postest: n, columnas, fecha de cierre, versión
- Registro de participación final y mortalidad (S7)
- Actas de aplicación y registro de incidencias
- Instrumentos físicos foliados o exportaciones del sistema
- Diccionario v0 y matriz de operacionalización
- Relación código–identidad (bajo custodia, fuera de la base)

Congelar el RAW

- Copiar cada base a la carpeta 01_RAW con nombre fechado
- Marcar como solo lectura y proteger la hoja
- Calcular y anotar el hash (SHA-256) en la bitácora
- Registrar n de filas y columnas como línea base del control
- Trabajar siempre sobre copias en 02_TRABAJO
- Producto del paso: inventario firmado + RAW congelado

Paso 2: estandarizar la estructura de ambas bases

2 Paso 2 de 7 · Estandarizar la estructura

- Mismas variables, con el mismo nombre y tipo, en el pretest y el postest; solo cambia el sufijo (_PRE / _POST).
- Código de participante con un patrón único: GE-### / GC-###; se normaliza con MAYUSC, ESPACIOS y ceros a la izquierda.
- Mismo orden de columnas, una hoja por tabla, sin celdas combinadas ni filas de totales.
- Categorías en números con etiqueta (CARGO 1/2/3), fechas ISO, decimales con punto, unidades fijas.
- Producto del paso: dos copias de trabajo estructuralmente idénticas, listas para cruzarse.

Antes (postest recibido)

Codigo	tiempo post	Cargo
ge-012	7,4	Tecnico
GC-17	264	PROFESIONAL

Después (copia de trabajo estandarizada)

ID	TIEMPO_POST	CARGO
GE-012	7.4	2
GC-017	11.0	3

Excel: =MAYUSC(ESPACIOS(A2)) normaliza el código; =IZQUIERDA(A2;3)&TEXTO(VALOR(DERECHA(A2;LARGO(A2)-3));"000") repone los ceros.

Paso 3: integrar las bases por la clave

3

Paso 3 de 7 · Integrar por clave

Primero una combinación externa (outer join)

Conserva todos los códigos y muestra quién no cruza; después se filtra a los emparejados (inner).

Verificaciones inmediatas

- n_pre, n_post, emparejados y huérfanos por grupo
- Ningún código con más de un postest (1:1)

Excel / Calc

```
=SI.ERROR(INDICE(POST!D:D;
 COINCIDIR($A2;POST!A:A;0));
 "")
```

Vacío = sin postest (huérfano).

Evite BUSCARV: falla al mover columnas.

SPSS / Jamovi

Datos → Fusionar archivos → Añadir variables

Clave: ID (ambos ordenados)

Marcar casos no apareados

Python / R

```
pd.merge(pre, post, on='ID',
  how='outer', indicator=True)
df['_merge'].value_counts()
dplyr::full_join(pre, post,
  by='ID')
```

Paso 4: conciliar la correspondencia de participantes

4

Paso 4 de 7 · Conciliar la correspondencia

Situación detectada	Qué hacer	Dónde se documenta
Emparejado (1 pre, 1 post)	Pasa al análisis (INCLUIR = 1)	Tabla de conciliación
Huérfano de pretest (sin postest)	Cruzar con el registro de mortalidad; excluir del apareado; reportar n	Mortalidad + bitácora
Huérfano de postest (sin pretest)	¿Código mal escrito? Si es ingreso tardío, excluir	Bitácora
Duplicado exacto	Eliminar la segunda ocurrencia	Bitácora
Duplicado con valores distintos	Verificar el folio físico; conservar el válido	Bitácora + folio
Código mal escrito	Normalizar al patrón y volver a cruzar	Bitácora
Retiro de consentimiento	Excluir y eliminar del análisis; registrar el hecho	Registro ético + bitácora

Producto del paso: conciliación con 0 duplicados, 0 códigos no reconocidos y 0 huérfanos sin explicación.

Paso 5: codificar y derivar variables en el orden correcto

5

Paso 5 de 7 · Codificar y derivar

1. Categorías de texto → códigos numéricos con etiqueta
2. Ítems inversos → recodificar (6 − x)
3. Dimensiones → promedio de ítems completos
4. Totales → suma de ítems completos
5. Niveles → baremo declarado
6. Diferencias → POST − PRE
7. Diccionario → actualizar a v1.0

Comprobaciones

- Suma de ítems = total en 3 casos al azar
- Ningún total fuera de 15–75
- Frecuencia de NIVEL coherente con la media

Qué se conserva

- Copia de trabajo: valores originales
- Base consolidada: valores recodificados
- Diccionario: explica la transformación

Paso 6 (a): control de calidad de completitud y rango

6 Paso 6 de 7 · Controlar la calidad

Indicador	Cómo se calcula	Meta	Si no se cumple
Duplicados pendientes	CONTAR.SI(ID) > 1 en cada copia de trabajo	0	Resolver (paso 4)
Huérfanos sin motivo	Conciliación − registro de mortalidad	0	Buscar el motivo o excluir
Tasa global de perdidos	Vacíos ÷ (variables × casos incluidos)	< 2 %	Recuperar; aplicar criterios
Perdidos por variable	CONTAR.BLANCO por columna ÷ n	< 5 %	Describir el mecanismo
Casos con imputación	FLAG_IMP = 1	≤ 5 %	Reportar sensibilidad
Fuera de rango	CONTAR.SI fuera del rango del diccionario	0	Verificar; corregir o perder
No numéricos en numéricas	CONTARA − CONTAR por columna	0	Convertir el formato

La hoja 6_Control_Calidad calcula estos indicadores con semáforo y bloquea la liberación mientras haya un rojo.

Paso 6 (b): control de calidad de atípicos, consistencia y formato

6 Paso 6 de 7 · Controlar la calidad

Indicador	Cómo se calcula	Meta	Si no se cumple
Atípicos por grupo y momento	Límites de Tukey (CUARTIL.INC) por GE/GC en PRE, POST y DIF	Verificados	Corregir, perder o conservar
Consistencia entre variables	EXPERIENCIA ≤ EDAD − 18; total = suma de ítems	0	Verificar ficha o folio
Consistencia temporal	Fechas dentro de sus ventanas; POST > PRE	0	Corregir con el acta
Formato	Fechas reales; decimales con punto; sin texto	0	Convertir y registrar
Unidades	Máximo y mínimo plausibles según el diccionario	0	Convertir (horas → días)
Codificación	Frecuencias por categoría; inversos recodificados	100 %	Codificar; recodificar

Producto del paso: matriz de hallazgos (uno por fila) para aplicar los criterios de depuración.

Criterios de depuración (1/2): correspondencia y valores

Hallazgo	Criterio	Acción	Registro
Duplicado exacto	La repetición no aporta información	Eliminar la 2.ª ocurrencia	Bitácora
Duplicado con valores distintos	Manda el instrumento físico	Conservar el que coincide con el folio	Bitácora + folio
Código mal escrito	Normalizar antes de cruzar	MAYUSC, ESPACIOS, ceros	Bitácora
Sin postest (mortalidad)	Casos completos apareados	Excluir del apareado; reportar n y motivo	Mortalidad + bitácora
Sin pretest (ingreso tardío)	Sin línea base no hay diferencia	Excluir	Bitácora
Retiro de consentimiento	Ética primero	Excluir y eliminar del análisis	Registro ético
Fuera de rango	Verificar la fuente	Corregir; si no hay fuente, perdido	Bitácora
Formato o unidad	Un tipo y una unidad por columna	Convertir (8,5 → 8.5; 264 h → 11 d)	Bitácora

Criterios de depuración (2/2): perdidos, atípicos e inconsistencias

Hallazgo	Criterio	Acción	Registro
Perdido recuperable	La fuente primaria tiene el dato	Recuperar y citar la evidencia	Bitácora
Ítem perdido ≤ 20 % de la dimensión	Media de la persona	Imputar y marcar FLAG_IMP = 1	Bitácora + sensibilidad
Ítems perdidos > 20 %	No imputar	Dimensión y total perdidos; caso sigue en otras variables	Bitácora
VD principal perdida	Casos completos	Excluir del análisis de esa variable; reportar n	Bitácora
Atípico por error	Verificar y corregir	Valor de la fuente	Bitácora
Atípico genuino	Conservar	Sensibilidad con y sin el caso	Bitácora + Cap. IV
Inconsistencia lógica	Verificar acta o ficha	Corregir; si no se resuelve, perdido	Bitácora
Codificación inconsistente	Un código por categoría	Codificar; recodificar inversos	Diccionario

Paso 7: documentar y liberar la base consolidada v1.0

7

Paso 7 de 7 · Documentar y liberar v1.0

Lista de liberación

- Bitácora completa: un hallazgo por fila, con evidencia
- Diccionario v1.0 con las 57 variables (en el caso)
- Ficha de control de calidad sin indicadores en rojo
- Lista de cotejo 14/14 (o 12–13 con observaciones)
- Revisión cruzada firmada por el par
- Hoja protegida, archivo versionado y respaldado (3-2-1)
- Hash de la versión anotado en la bitácora

Entregar

TESIS_BD_CONSOLIDADA_v1.0_AAAA-MM-DD.xlsx al asesor y a la Tarea Académica 3; copia en los Anexos 8 (bases) y 9 (diccionario).

Congelar

Desde aquí, ningún cambio sin nueva versión (v1.1) y motivo. El Capítulo IV se calcula únicamente sobre la versión liberada.

Estructura de carpetas y nombres recomendados

```
TESIS_[APELLIDO]/
├─ 00_DOCS/        protocolo y actas
├─ 01_RAW/         originales (solo lectura)
│   ├─ BD_PRETEST_RAW_2026-08-31.xlsx
│   └─ BD_POSTEST_RAW_2026-10-19.xlsx
├─ 02_TRABAJO/     copias de trabajo
├─ 03_CONSOLIDADA/ versiones liberadas
│   └─ BD_CONSOLIDADA_v1.0_2026-10-24.xlsx
├─ 04_ANALISIS/    salidas SPSS/Jamovi/R
├─ 05_ANEXOS/      diccionario, bitácora, QC
└─ 99_PRIVADO/     código–identidad (cifrada)
```

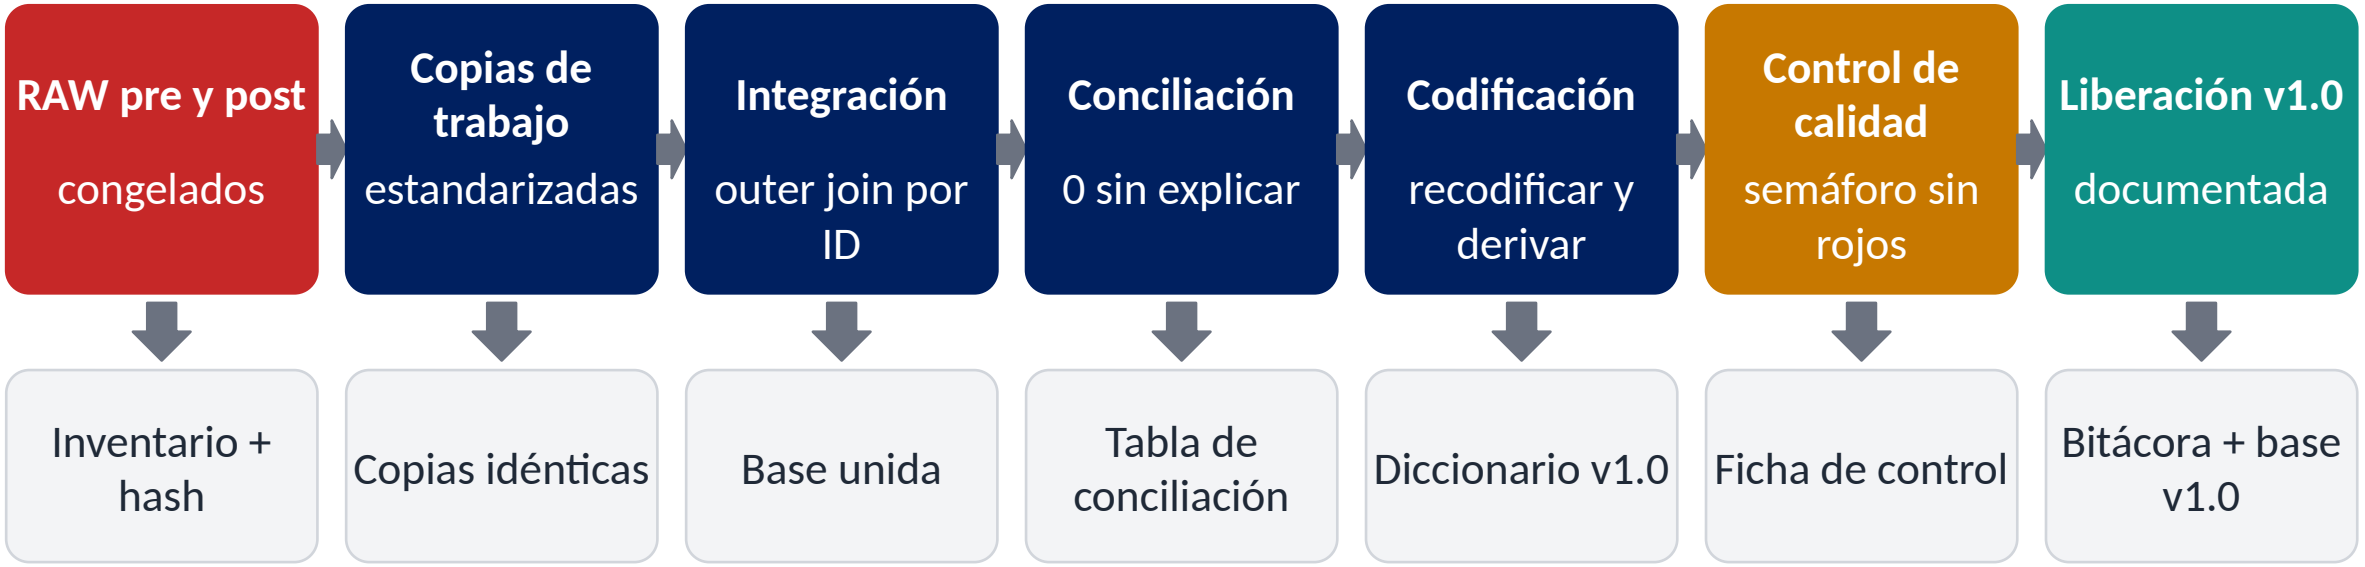
Reglas de nombre

- Qué es + estado + versión + fecha ISO
- Sin espacios ni tildes; guiones bajos
- La versión solo sube; nunca se sobrescribe
- Un archivo liberado = un hash

Dónde vive cada cosa

- 99_PRIVADO nunca se comparte
- 01_RAW nunca se edita
- 03_CONSOLIDADA es lo que ve el jurado
- 04_ANALISIS reproduce el Cap. IV

El flujo completo en una página



Actitudes

Precisión, confidencialidad, honestidad, transparencia, perseverancia y responsabilidad.

Revisión cruzada

Un par verifica con la lista de cotejo y recalcula tres indicadores al azar.

Siguiente sesión

S10: descriptivos por objetivos sobre la base v1.0 liberada hoy.

Caso aplicado: la misma tesis de las sesiones anteriores

«Sistema web de gestión documental y su influencia en el tiempo de atención de expedientes en una municipalidad de Huánuco, 2026»

Elemento	Detalle
Diseño	Cuasiexperimental con grupo de comparación no equivalente (GE: O_1 X O_2 · GC: O_3 — O_4)
Grupos	GE: sede central, n = 24 · GC: sede descentralizada, n = 22 (servidores de trámite documentario)
Cronograma	Pretest 24–28/08 · Intervención 31/08–09/10 (6 semanas) · Postest 12–16/10/2026
VD 1 (observación documental)	TIEMPO: días promedio de atención por expediente · CUMPLE: % dentro del plazo
VD 2 (encuesta)	Satisfacción: 15 ítems Likert 1–5 en 3 dimensiones (S04 y S12 inversos)
Covariables	SEXO, EDAD, EXPERIENCIA, CARGO (auxiliar, técnico, profesional)
Insumos de la S7	Base del postest, mortalidad (GE 24→22; GC 22→20) y retiro de consentimiento de GE-019

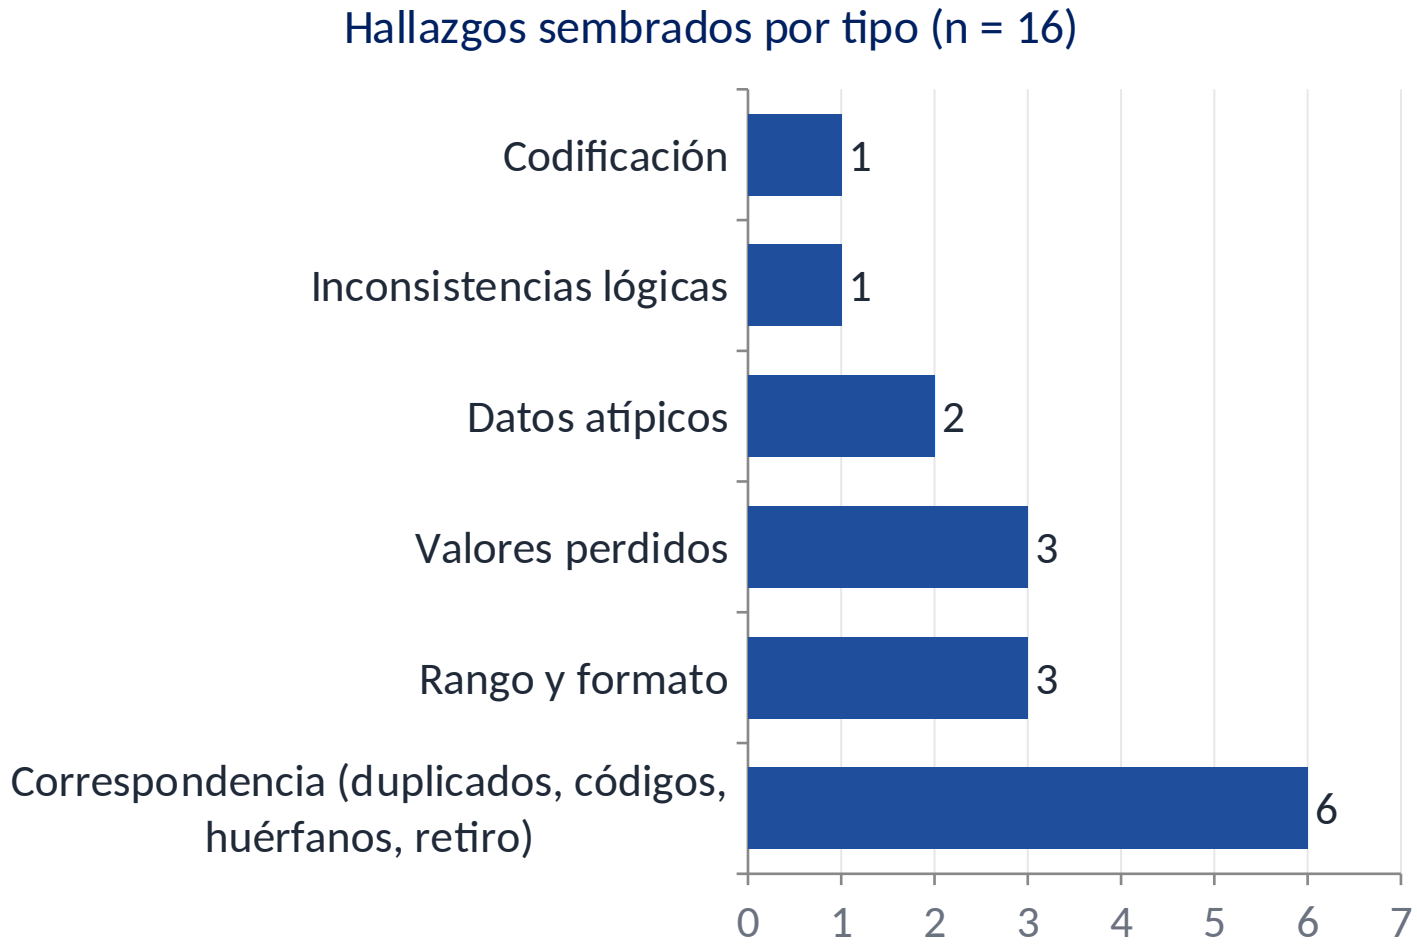
Inventario de insumos y panorama de los 16 hallazgos

47 / 46 filas / códigos en el pretest RAW

44 / 43 filas / códigos en el postest RAW

4 + 1 pérdidas muestrales + retiro de consentimiento

24 · 20 columnas en pretest · postest



Conciliación del caso: qué mostró la tabla antes de corregir

Código	Registros PRE	Registros POST	Estado inicial	Lectura del equipo
GE-003	2	1	DUPLICADO EN PRE	Dos filas con S07 distinto → decide el folio N° 003
GE-007	1	0	Huérfano de pretest	Traslado de sede (06/09): mortalidad documentada
GE-012	1	1*	Emparejado	*Decía «ge-012»: COUNTIF no distingue mayúsculas
GE-019	1	1	Emparejado	Retiro de consentimiento (15/10): se excluye igual
GC-005	1	2	DUPLICADO EN POST	Filas idénticas → eliminar la segunda
GC-017	1	0	Huérfano de pretest	Falso huérfano: el postest decía «GC-17»
GC-023	0	1	Huérfano de postest	Ingreso tardío sin pretest → excluir



Tras corregir: 42 emparejados, 4 huérfanos de pretest con motivo, 1 huérfano de postest excluido, 0 duplicados, 0 códigos no reconocidos → 41 casos analizados (GE 21, GC 20)

Los 16 hallazgos y sus decisiones (1/2)

N°	Código · variable	Valor encontrado	Decisión y criterio
H01	GC-005 · fila completa	2 filas idénticas en el postest	Eliminar la 2.ª ocurrencia (duplicado exacto)
H02	GE-003 · S07_PRE	4 y 2 en dos filas del pretest	Conservar 4: coincide con el folio N° 003
H03	GE-012 / GC-017 · ID	«ge-012», «GC-17»	Normalizar al patrón GE-### / GC-###
H04	GC-023 · registro	Postest sin pretest	Excluir: ingreso tardío sin línea base
H05	GE-007, GE-013, GC-008, GC-014	Sin postest	Excluir del apareado: mortalidad documentada en S7
H06	GE-019 · registro	Retiro de consentimiento tras el postest	Excluir y eliminar del análisis; registrar
H07	GE-010 · S05_POST	6 (fuera de 1–5)	Corregir a 5 según folio N° 010
H08	GC-011 · EDAD	7	Corregir a 37 según ficha de datos

Los 16 hallazgos y sus decisiones (2/2)

N°	Código · variable	Valor encontrado	Decisión y criterio
H09	GC-003 · TIEMPO_PRE	«8,5» como texto	Convertir a 8.5 numérico
H10	GE-015 · S13_PRE	Vacío (1 de 5 ítems de D3)	Imputar media de la persona; FLAG_IMP = 1
H11	GC-009 · S02_POST, S03_POST	Vacíos (2 de 5 ítems de D1)	No imputar: D1 y total del postest perdidos
H12	GE-022 · TIEMPO_POST	Vacío	Recuperar del registro documental: 6.8
H13	GE-011 · TIEMPO_PRE	48.0 (límite de Tukey 18.6)	Genuino: conservar + sensibilidad
H14	GC-016 · TIEMPO_POST	264 (registrado en horas)	Convertir a 11.0 días
H15	GE-004 · FECHA_POST / GC-002 · EXPERIENCIA	2026-09-14 / 25 años (edad 23)	Corregir con acta (2026-10-14) y ficha (2)
H16	Todos · CARGO, S04, S12	Texto inconsistente; inversos sin recodificar	Codificar 1/2/3; recodificar 6 − x

Valores perdidos del caso: tres situaciones, tres decisiones

GE-015 · S13_PRE

- **1 de 5 ítems de D3 (20 %)**
- Imputación por media de la persona en D3 (S11, S12 recodificado, S14, S15). FLAG_IMP = 1. Se reporta sensibilidad.

GC-009 · S02_POST y S03_POST

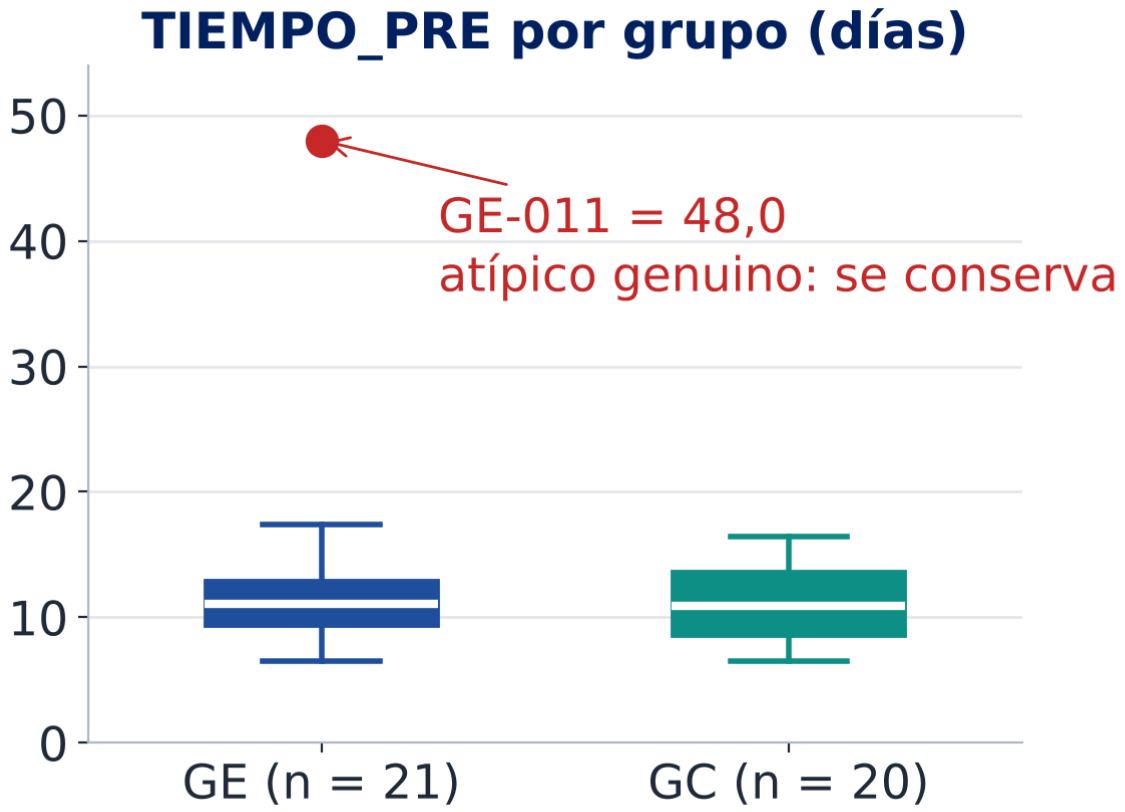
- **2 de 5 ítems de D1 (40 %)**
- No se imputa: D1_POST, SAT_TOTAL_POST, NIVEL_SAT_POST y DIF_SAT quedan perdidos. El caso se conserva para TIEMPO, CUMPLE, D2 y D3.

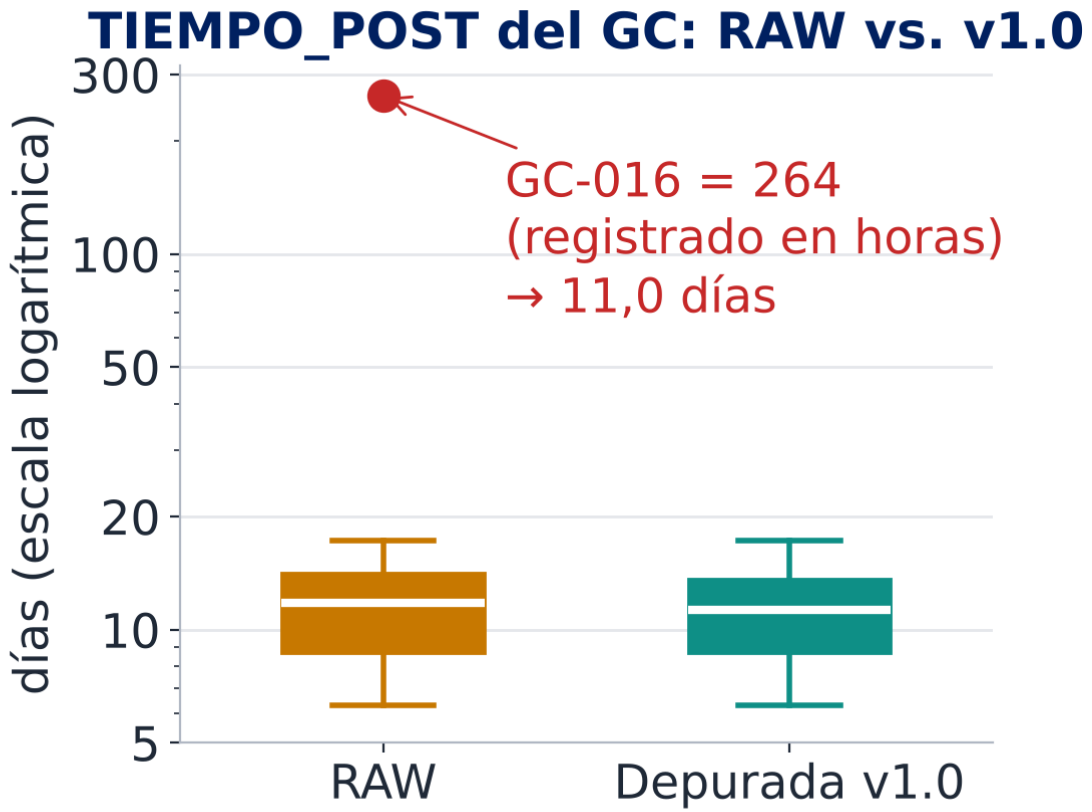
GE-022 · TIEMPO_POST

- **Celda vacía en la base**
- Se recupera del registro de trámite documentario (log): 6.8 días. Evidencia citada en la bitácora.

Indicador de completitud	RAW	Base v1.0
Celdas vacías en variables de análisis	4 (en 2 008 celdas) = 0,20 %	2 (en 1 394 celdas) = 0,14 %
Casos con alguna dimensión perdida	2 (GE-015, GC-009)	1 (GC-009)
Casos con imputación (FLAG_IMP)	0	1 (GE-015)
n válido para la prueba de SAT_TOTAL (S11)	—	40 (GE 21, GC 19)

Datos atípicos del caso: uno genuino y uno por error de unidad

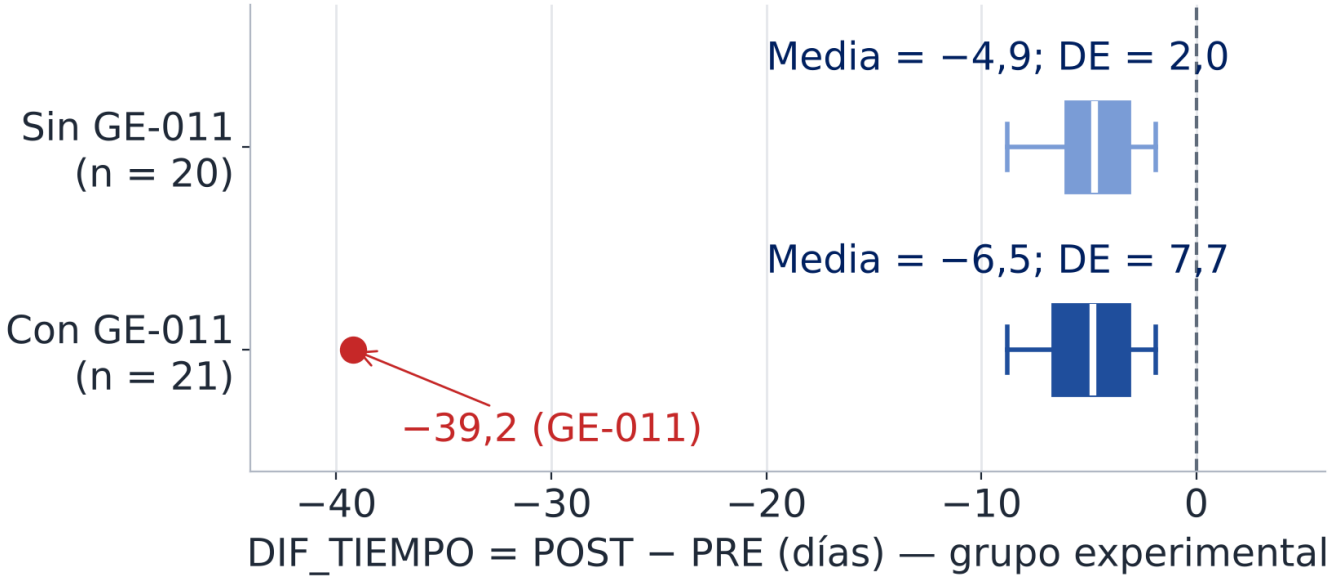




GE-011 = 48,0 días: verificado en el registro (expediente complejo) → se conserva

GC-016 = 264: registrado en horas → 264 ÷ 24 = 11,0 días

Análisis de sensibilidad del atípico genuino



Con GE-011 (n = 21): media de la diferencia −6,5 días; DE 7,7; un atípico extremo (−39,2).

Sin GE-011 (n = 20): media −4,9 días; DE 2,0; ningún atípico.

Lectura: la dirección y la significancia práctica del cambio no dependen del caso; cambia la dispersión.

Consecuencia para S11: la diferencia probablemente no sea normal con el caso incluido → Wilcoxon como prueba principal o reporte de ambos escenarios.

Escenario	n	Media DIF_TIEMPO	DE	Mediana	Atípicos
Base v1.0 completa	21	−6,5	7,7	−4,8	1 (GE-011)
Sin GE-011	20	−4,9	2,0	−4,8	0

El análisis de sensibilidad se reporta en el Capítulo IV como nota a la tabla de la prueba y se discute en el Capítulo V como fortaleza metodológica.

Bitácora de depuración del caso (extracto)

N°	Código · variable	Original → nuevo	Tipo	Criterio aplicado	Evidencia
1	GC-005 · fila	2 filas → 1	Duplicado exacto	Eliminar 2.ª ocurrencia	COUNTIF > 1; folio 027
2	GE-003 · S07_PRE	4 / 2 → 4	Duplicado distinto	Manda el folio físico	Pretest, folio N° 003
7	GE-010 · S05_POST	6 → 5	Fuera de rango	Verificar y corregir	Postest, folio N° 010
10	GE-015 · S13_PRE	vacío → media D3	Perdido aislado	Media de la persona	Folio N° 015 sin marcar
12	GE-022 · TIEMPO_POST	vacío → 6.8	Perdido recuperable	Recuperar de la fuente	Log de trámite 21/09–09/10
13	GE-011 · TIEMPO_PRE	48.0 → 48.0	Atípico genuino	Conservar + sensibilidad	Registro de trámite
14	GC-016 · TIEMPO_POST	264 → 11.0	Atípico por unidad	Convertir horas a días	Nota del aplicador

Bitácora completa (16 filas con fecha, responsable y revisor) en la hoja 8_Bitacora del cuaderno docente.

Ficha de control de calidad del caso: antes y después

Indicador	RAW (antes)	Base v1.0 (después)	Meta	Estado
Duplicados pendientes	2	0	0	**VERDE**
Códigos no reconocidos	1	0	0	**VERDE**
Huérfanos sin motivo documentado	1	0	0	**VERDE**
Tasa global de perdidos	0,20 %	0,14 %	< 2 %	**VERDE**
Valores fuera de rango	3	0	0	**VERDE**
Valores no numéricos en numéricas	47	0	0	**VERDE**
Inconsistencias lógicas	3	0	0	**VERDE**
Atípicos verificados (genuinos conservados)	4	1 (GE-011)	documentados	**ÁMBAR**
Casos con imputación	0	1 (GE-015)	≤ 5 %	**ÁMBAR**
Casos analizados (GE / GC / total)	—	21 / 20 / 41	según conciliación	**VERDE**

0 indicadores en rojo → «BASE LISTA PARA LIBERAR (v1.0)»; los ámbar están justificados en la bitácora.

Resultado: base v1.0 y su reflejo en el Capítulo IV

41
casos analizados
(GE 21 · GC 20)

57
variables
(+ columna INCLUIR)

16
hallazgos resueltos
y documentados

0,14 %
celdas perdidas
en variables de análisis

Párrafo modelo para el apartado 4.1 (caracterización de la muestra)

«La base consolidada quedó conformada por 41 servidores (GE = 21; GC = 20) de los 46 que iniciaron el estudio. Se excluyeron cuatro casos por pérdida muestral documentada (traslado, licencia, renuncia y vacaciones prolongadas) y uno por retiro del consentimiento informado; un registro de postest sin pretest fue descartado. El control de calidad identificó y resolvió 16 hallazgos (duplicados, códigos inconsistentes, valores fuera de rango, errores de formato y de unidad, valores perdidos y un atípico genuino), documentados en la bitácora de depuración (Anexo 8). La tasa de celdas perdidas fue de 0,14 %; un ítem fue imputado por media de la persona y un caso presenta la dimensión 1 del postest como perdida, por lo que el n válido para la satisfacción total es 40».

Instrumentos de evaluación de la sesión

Instrumento	Qué evalúa	Quién lo aplica	Cuándo	Escala / peso
Lista de cotejo de base de datos	14 criterios verificables de estructura, correspondencia, codificación, calidad y documentación	Par revisor y docente	Revisión cruzada (en clase)	Sí / No / N.A. · 14/14 lista; 12–13 con observaciones
Ficha de control de calidad	Indicadores con meta y semáforo sobre la base consolidada	Tesista (autocontrol) + par	Antes de liberar la v1.0	0 rojos para liberar; ámbar justificado
Rúbrica de depuración	Calidad de las decisiones: detección, criterio, justificación y trazabilidad	Docente	Entrega del laboratorio / TA3	5 criterios × 4 niveles = 20 puntos
Revisión del diccionario de variables	Completitud y exactitud del codebook v1.0	Docente y asesor	Entrega de la TA3 (Anexo 9)	10 criterios · 10/10 aprobado; 8–9 ajustar

Los cuatro instrumentos están listos para imprimir (Word) y en versión digital en el cuaderno Excel.

Lista de cotejo de la base de datos consolidada (14 criterios)

1. RAW intacto, protegido, con fecha y hash
2. Formato ancho: 1 fila por participante, 1 columna por variable
3. Códigos únicos con el patrón definido (0 duplicados)
4. Cada pretest tiene postest o motivo documentado
5. Registros sin pretest excluidos y documentados
6. Retiros de consentimiento excluidos y registrados
7. Nombres de variables según convención (_PRE/_POST)
8. Categóricas codificadas; ítems inversos recodificados
9. Valores dentro del rango válido del diccionario
10. Solo números en numéricas; fechas AAAA-MM-DD
11. Perdidos cuantificados, tratados y marcados (FLAG_IMP)
12. Atípicos detectados, verificados y decididos
13. Inconsistencias lógicas resueltas contra la fuente
14. Bitácora, diccionario v1.0 y ficha completos; versión v1.0 respaldada

Resultado: 14/14 → lista para liberar · 12–13 → liberar con observaciones · < 12 → revisar con el asesor antes de analizar

Ficha de control de calidad: indicadores, metas y semáforo

Indicador	Meta	Verde	Ámbar	Rojo
Duplicados, códigos no reconocidos, huérfanos sin motivo	0	0	—	≥ 1
Tasa global de perdidos	< 2 %	< 2 %	2–5 % justificado	> 5 %
Perdidos por variable	< 5 %	< 5 %	5–20 % con mecanismo	> 20 %
Casos con imputación	≤ 5 %	0	≤ 5 % con flag	> 5 % o sin flag
Fuera de rango, no numéricos, inconsistencias	0	0	—	≥ 1
Atípicos	Verificados	0	Genuinos declarados	Sin verificar
Documentación	Completa	Bitácora + diccionario + hash	Falta un elemento menor	Sin bitácora

Regla de liberación: 0 indicadores en rojo. Firman el responsable y el par revisor (hoja 6_Control_Calidad).

Rúbrica de depuración (5 criterios × 4 niveles = 20 puntos)

Criterio	Destacado (4)	Logrado (3)	En proceso (2)	En inicio (1)
1. Integración y correspondencia	Outer join; conciliación con 0 sin explicar	Conciliación con 1 omisión menor	Huérfanos o duplicados sin resolver	Bases no integradas o mal emparejadas
2. Codificación y diccionario	Convención, inversos, derivadas y codebook completos	Codebook con campos menores incompletos	Codificación parcial; inversos sin recodificar	Sin diccionario ni codificación
3. Detección de hallazgos	Detecta ≥ 14 de 16 con reglas reproducibles	Detecta 11–13	Detecta 7–10	Detecta < 7 o solo por inspección
4. Criterios de depuración	Criterio correcto y justificado en todos los casos	Criterio correcto con 1–2 errores	Decisiones ad hoc o sin justificar	Elimina o imputa sin criterio
5. Documentación y trazabilidad	Bitácora completa, versionado, hash, confidencialidad	Bitácora completa; versionado parcial	Bitácora incompleta	Sin bitácora; RAW editado

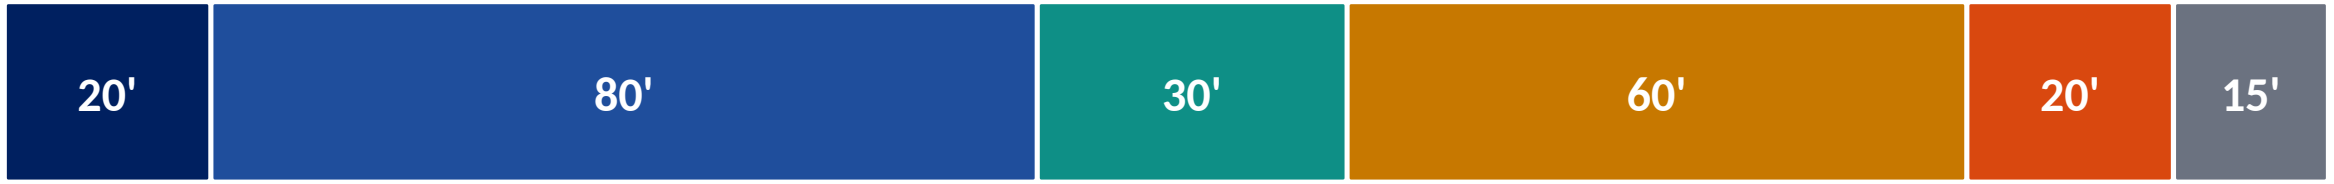
Escala: 17–20 destacado · 13–16 logrado · 9–12 en proceso · 5–8 en inicio (escala vigesimal del laboratorio).

Revisión del diccionario de variables (10 criterios)

1. Incluye todas las variables de la base consolidada (ninguna sin fila)
2. Nombres idénticos a los encabezados de la base
3. Etiqueta clara y sin ambigüedad para cada variable
4. Tipo de dato y nivel de medición correctos
5. Códigos de categorías con su significado (1 = …; 2 = …)
6. Rango válido y unidad declarados en las numéricas
7. Instrumento, ítem y momento (pre/post) de cada variable
8. Fórmula de derivación de dimensiones, totales, niveles y DIF
9. Código de perdido y tratamiento de inversos explícitos
10. Versión, fecha y correspondencia con la matriz de operacionalización

Decisión: 10/10 aprobado (Anexo 9) · 8–9 ajustar antes de la TA3 · < 8 rehacer con el asesor. Cada «No» se anota con la variable afectada.

Secuencia didáctica de la sesión (225 minutos)



Inicio	Pregunta detonante, recojo de saberes (S3 y S7), ficha del sílabo y producto esperado
Desarrollo teórico	Marco conceptual (45) y protocolo de 7 pasos (35) con demostraciones en Excel
Caso aplicado	Lectura guiada de los 16 hallazgos y de las decisiones; discusión de alternativas
Laboratorio de datos	Equipos de 2–3 resuelven el cuaderno con los hallazgos sembrados y llenan la bitácora
Revisión cruzada	Intercambio de bases, lista de cotejo, recálculo de indicadores y observaciones
Cierre	Ideas fuerza, metacognición (¿qué haré distinto con mi base?) y tarea para la TA3

Laboratorio de datos: el reto de los 16 hallazgos

Consigna

Con el cuaderno Lab_Sesion_9_Consolidacion_Estudiante.xlsx, integre las bases RAW del pretest y el postest, verifique la correspondencia, codifique y derive las variables, y detecte y resuelva los 16 hallazgos con los criterios de la sesión. Documente cada decisión en la bitácora.

Materiales

- Cuaderno Excel del estudiante (10 hojas con fórmulas y semáforo)
- Instrumentos impresos (Word): cotejo, ficha, rúbrica y revisión
- Excel o LibreOffice Calc; SPSS, Jamovi, R o Python opcionales
- Clave de los 16 hallazgos: solo el docente

1. Inventariar y registrar filas, columnas y fecha del RAW
2. Copiar a las hojas de trabajo y normalizar los códigos
3. Leer la conciliación y resolver duplicados y huérfanos
4. Revisar el semáforo de control de calidad y corregir
5. Decidir INCLUIR y FLAG_IMP; completar el diccionario
6. Llenar la bitácora y obtener «BASE LISTA PARA LIBERAR»

Revisión cruzada: guion de 20 minutos

0–3'	Intercambiar cuadernos y bitácoras entre equipos (A revisa a B, B revisa a C…)
3–10'	Aplicar la lista de cotejo de 14 criterios anotando la evidencia (hoja y celda)
10–14'	Recalcular tres indicadores al azar de la ficha de control de calidad
14–17'	Escribir observaciones: qué falta, qué decisión no tiene criterio, qué no está en la bitácora
17–20'	Devolver; el autor responde cada observación en su bitácora y ambos firman la ficha

El revisor no corrige

Observa, pregunta y verifica; la decisión y el registro son del autor.

Actitud evaluada

Honestidad al recibir observaciones y transparencia al documentarlas.

Actitudes del sílabo traducidas en conductas observables

Precisión

Verifica cada valor contra la fuente antes de darlo por válido; calcula, no estima.

Confidencialidad

Trabaja solo con códigos; no muestra ni comparte la tabla código–identidad.

Honestidad

Registra también los hallazgos que no favorecen su hipótesis; no elimina casos «incómodos».

Transparencia

Toda decisión tiene fila en la bitácora y puede ser reconstruida por otro.

Perseverancia

Agota las fuentes (folio, log, acta) antes de declarar un perdido.

Responsabilidad

Libera la base solo con el semáforo en verde y asume la autoría de cada decisión.

Errores frecuentes en la consolidación (1/2)

Error	Consecuencia	Prevención
Editar directamente el RAW	Se pierde la posibilidad de volver atrás y de demostrar qué se cambió.	Congelar el RAW; trabajar en copias con bitácora.
Cruzar bases sin normalizar los códigos	Casos válidos aparecen como pérdidas (GC-17 ≠ GC-017).	Patrón único + MAYUSC/ESPACIOS antes de cruzar.
Hacer la combinación interna de entrada	Los huérfanos desaparecen sin explicación.	Outer join primero; luego filtrar.
Sumar ítems sin recodificar los inversos	Totales y confiabilidad distorsionados.	Recodificar (6 − x) antes de derivar.
Usar 0 o «NA» como código de perdido	Entra en promedios y sumas sin avisar.	Celda vacía o 999 declarado.

Errores frecuentes en la consolidación (2/2)

Error	Consecuencia	Prevención
Eliminar atípicos sin verificar la fuente	Se pierde información real y se manipula el resultado.	Verificar; conservar genuinos con sensibilidad.
Imputar sin regla ni marca	No se puede evaluar el efecto de la imputación.	Regla ≤ 20 % + FLAG_IMP + sensibilidad.
Promedios con celdas vacías	Dimensiones «completas» que no lo son.	Exigir CONTAR = n de ítems.
Mezclar GE y GC en una sola distribución	Atípicos y rangos mal evaluados.	Controles por grupo y por momento.
Entregar una base con nombres o DNI	Falta ética y legal (Ley N.° 29733).	Solo códigos; tabla de identidad aparte y cifrada.
Cambiar la base después de liberarla	El Capítulo IV deja de coincidir con los anexos.	Nueva versión (v1.1) con motivo registrado.

Entregables para la TA3 y el informe final

Para la TA3 (Capítulo IV: Resultados)

- Base consolidada v1.0 protegida y versionada
- Diccionario de variables v1.0
- Bitácora de depuración completa
- Ficha de control de calidad y lista de cotejo firmadas

En el informe final

- Anexo 8: bases codificadas (pretest, postest, consolidada)
- Anexo 9: diccionario de variables
- Anexo 10: salidas del software (control de calidad)
- Apartado 4.1: n final, exclusiones y nota de depuración

Semana	Qué se hace con la base v1.0	Producto
10	Caracterización de la muestra y descriptivos pre–post por objetivos	Tablas y figuras del 4.1
11	Hipótesis estadísticas, normalidad y homogeneidad; selección de la prueba	Ficha de verificación de supuestos
12	Contrastación, intervalos de confianza, tamaño del efecto; redacción del Capítulo IV	Capítulo IV completo (TA3)

Ideas fuerza de la sesión

1. Ninguna estadística corrige un dato mal registrado o mal emparejado: la calidad se gana antes del análisis.

2. En diseños con medición repetida, la correspondencia pretest–postest por código es condición de validez.

3. Los criterios de depuración se fijan antes de ver su efecto y se aplican igual a todos los casos.

4. Recuperar precede a imputar; imputar precede a perder; perder precede a inventar (que está prohibido).

5. Un atípico es una señal para verificar, nunca una orden para eliminar.

6. Lo que no está en la bitácora no existió: la trazabilidad es la forma visible de la honestidad científica.

Referencias (1/4)

Aguinis, H., Gottfredson, R. K., & Joo, H. (2013). Best-practice recommendations for defining, identifying, and handling outliers. Organizational Research Methods, 16(2), 270–301. https://doi.org/10.1177/1094428112470848

Barchard, K. A., & Pace, L. A. (2011). Preventing human error: The impact of data entry methods on data accuracy and statistical results. Computers in Human Behavior, 27(5), 1834–1839. https://doi.org/10.1016/j.chb.2011.04.004

Bennett, D. A. (2001). How can I deal with missing data in my study? Australian and New Zealand Journal of Public Health, 25(5), 464–469. https://doi.org/10.1111/j.1467-842X.2001.tb00294.x

Broman, K. W., & Woo, K. H. (2018). Data organization in spreadsheets. The American Statistician, 72(1), 2–10. https://doi.org/10.1080/00031305.2017.1375989

Downey, R. G., & King, C. V. (1998). Missing data in Likert ratings: A comparison of replacement methods. The Journal of General Psychology, 125(2), 175–191. https://doi.org/10.1080/00221309809595542

Enders, C. K. (2022). Applied missing data analysis (2.ª ed.). Guilford Press.

Referencias (2/4)

Hernández-Sampieri, R. (2022). Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta (7.ª ed.). McGraw-Hill.

International Organization for Standardization. (2008). ISO/IEC 25012:2008. Software engineering — Software product Quality Requirements and Evaluation (SQuaRE) — Data quality model. ISO.

Jakobsen, J. C., Gluud, C., Wetterslev, J., & Winkel, P. (2017). When and how should multiple imputation be used for handling missing data in randomised clinical trials: A practical guide with flowcharts. BMC Medical Research Methodology, 17, 162. https://doi.org/10.1186/s12874-017-0442-1

Leys, C., Ley, C., Klein, O., Bernard, P., & Licata, L. (2013). Detecting outliers: Do not use standard deviation around the mean, use absolute deviation around the median. Journal of Experimental Social Psychology, 49(4), 764–766. https://doi.org/10.1016/j.jesp.2013.03.013

Ley N.° 29733, Ley de Protección de Datos Personales. (2011, 3 de julio). Diario Oficial El Peruano. Reglamento aprobado por Decreto Supremo N.° 016-2024-JUS.

Little, R. J. A., & Rubin, D. B. (2019). Statistical analysis with missing data (3.ª ed.). Wiley.

Referencias (3/4)

Ñaupas, H., Valdivia, M., Palacios, J., & Romero, H. (2018). Metodología de la investigación cuantitativa, cualitativa y redacción de la tesis (5.ª ed.). Ediciones de la U.

Osborne, J. W. (2013). Best practices in data cleaning: A complete guide to everything you need to do before and after collecting your data. SAGE.

Paulsen, A., Overgaard, S., & Lauritsen, J. M. (2012). Quality of data entry using single entry, double entry and automated forms processing: An example based on a study of patient-reported outcomes. PLoS ONE, 7(4), e35087. https://doi.org/10.1371/journal.pone.0035087

Peng, R. D. (2011). Reproducible research in computational science. Science, 334(6060), 1226–1227. https://doi.org/10.1126/science.1213847

Rubin, D. B. (1976). Inference and missing data. Biometrika, 63(3), 581–592. https://doi.org/10.1093/biomet/63.3.581

Schafer, J. L. (1999). Multiple imputation: A primer. Statistical Methods in Medical Research, 8(1), 3–15. https://doi.org/10.1177/096228029900800102

Referencias (4/4)

Shadish, W. R., Cook, T. D., & Campbell, D. T. (2002). Experimental and quasi-experimental designs for generalized causal inference. Houghton Mifflin.

Supo Condori, J. (2015). Cómo escribir una tesis (2.ª ed.). Bioestadístico EIRL.

Tukey, J. W. (1977). Exploratory data analysis. Addison-Wesley.

Universidad de Huánuco. (2018). Código de ética en investigación. Vicerrectorado de Investigación, UDH.

Van den Broeck, J., Argeseanu Cunningham, S., Eeckels, R., & Herbst, K. (2005). Data cleaning: Detecting, diagnosing, and editing data abnormalities. PLoS Medicine, 2(10), e267. https://doi.org/10.1371/journal.pmed.0020267

Wickham, H. (2014). Tidy data. Journal of Statistical Software, 59(10), 1–23. https://doi.org/10.18637/jss.v059.i10

Preguntas




¡Gracias!